

Wstęp do Uczenia Maszynowego

Projekt

Maria Eberhardt

05.01.2026

1 Problem projektu

Celem pracy jest zaproponowanie podejścia klasyfikacyjnego umożliwiającego zbudowanie modelu o możliwie najwyższej skuteczności predykcyjnej. Analizie poddano sztucznie wygenerowany zbiór danych artificial, w którym celowo ukryto zmienne istotne dla procesu klasyfikacji. Zadanie polega na przypisaniu obserwacji do jednej z dwóch klas, przy czym jako kryterium oceny jakości modelu zastosowano miarę zrównoważonej dokładności (balanced accuracy).

2 Opis danych i metryki oceny

Wykorzystywany zbiór artificial został udostępniony w postaci oddzielnych plików zawierających dane treningowe oraz dane testowe, przy czym część zmiennych w zbiorze miała rzeczywisty wpływ na przynależność do klasy, natomiast pozostałe pełniły rolę szumu, co utrudnia bezpośrednią identyfikację istotnych cech.

Dane treningowe składają się z dwóch elementów: zbioru cech wejściowych (X) oraz odpowiadających im etykiet klas (y). Zbiór ten został wykorzystany do uczenia modeli klasyfikacyjnych oraz porównywania różnych podejść. Dane testowe zawierają wyłącznie cechy wejściowe (X) i nie zawierają informacji o prawidłowych klasach, dlatego służą jedynie do wygenerowania końcowych predykcji przy użyciu wybranego modelu.

Na wstępnym etapie analizy przeprowadzono podstawowe sprawdzenia jakości danych, co pozwoliło upewnić się, że dane są poprawnie przygotowane do dalszej analizy i nie zawierają oczywistych błędów technicznych.

Wśród tych testów zostały zbadane wymiary zbiorów oraz ich zgodność - 1500 wierszy zarówno w X_{train} jak i y_{train} . Zbadano czy struktury zbiorów X_{train} jak i X_{test} są zgodne, tzn nie różnią się kolejnością kolumn, a także przebadano braki oraz typy danych. W powyższych testach nie wykryto żadnych nieprawidłowości.

W zbiorze treningowym obie klasy występują w zbliżonych proporcjach (755-745), co oznacza, że żadna z nich nie dominuje liczebnie. Do oceny jakości modeli zastosowano miarę zrównoważonej dokładności (balanced accuracy), która pozwala ocenić skuteczność klasyfikacji każdej z klas osobno, a następnie uśrednić uzyskane wyniki.

3 Model bazowy A0

Pierwszym krokiem analizy było zbudowanie prostego modelu bazowego, oznaczonego jako A0. Jego celem nie było osiągnięcie jak najlepszego wyniku, lecz uzyskanie punktu odniesienia, który pozwoli ocenić, czy i w jakim stopniu bardziej zaawansowane metody prowadzą do poprawy jakości klasyfikacji.

Model A0 został zbudowany w oparciu o podstawowy pipeline obejmujący minimalne przygotowanie danych oraz klasyfikator uczony na wszystkich dostępnych cechach. Pipeline modelu bazowego obejmował jedynie usunięcie cech niezmiennych oraz standaryzację danych, co pozwoliło ograniczyć wpływ zmiennych nieinformacyjnych i zapewnić spójne warunki uczenia modelu. Jako główny model została użyta Regresja Logistyczna.

Jakość modelu A0 oceniono z wykorzystaniem walidacji krzyżowej oraz miary balanced accuracy i otrzymano średnią Balanced Accuracy o wartości 0.5767. Uzyskany wynik był wyraźnie wyższy od wartości 0,5 odpowiadającej klasyfikacji losowej, co potwierdziło, że dane zawierają informację umożliwiającą predykcję przynależności do klasy. Jednocześnie wynik ten pozostawał na umiarkowanym poziomie, co wskazywało, że obecność wielu nieistotnych zmiennych oraz szumu ogranicza skuteczność prostego podejścia.

Model bazowy spełnił swoją rolę diagnostyczną: pozwolił potwierdzić istnienie sygnału w danych oraz uzasadnił potrzebę dalszych usprawnień, w szczególności związanych z redukcją szumu i wyborem najbardziej informacyjnych cech. Na tej podstawie w kolejnym etapie zaproponowano bardziej zaawansowane podejście oznaczone jako A1.

4 Usprawnienie oraz wybór modelu – podejście A1

Wyniki uzyskane dla modelu bazowego A0 wskazywały na obecność sygnału umożliwiającego klasyfikację, jednak jego skuteczność była ograniczona przez dużą liczbę zmiennych nieistotnych. W kolejnym etapie zaproponowano podejście A1, którego celem było ograniczenie wpływu szumu oraz poprawa jakości predykcji poprzez selekcję najbardziej informacyjnych cech oraz zastosowanie bardziej dopasowanych modeli końcowych.

Jako podstawowy mechanizm redukcji liczby cech wykorzystano algorytm Random Forest z parametrem 800 drzew, który umożliwia ocenę względnej ważności poszczególnych zmiennych w procesie klasyfikacji. Model ten został użyty wyłącznie jako narzędzie selekcyjne, a nie jako model końcowy. Na podstawie wyznaczonej ważności cech pozostawiono jedynie ograniczony podzbiór zmiennych o największym znaczeniu predykcyjnym, eliminując cechy, które wносиły głównie szum informacyjny. Podzbiór ten został ograniczony do 20 cech, co jako najbardziej optymalne potwierdziły późniejsze eksperymenty. Takie podejście pozwoliło uprościć problem oraz zwiększyć przejrzystość dalszego modelowania.

Cały proces przygotowania danych i uczenia modeli został zrealizowany w postaci jednolitego pipeline'u, który obejmował uzupełnianie ewentualnych braków danych, usunięcie cech stałych, selekcję zmiennych opartą na Random Forest oraz standaryzację cech. Zastosowanie pipeline'u zapewniło spójność przetwarzania danych oraz wyeliminowało ryzyko błędów wynikających z niejednolitego przygotowania danych na poszczególnych etapach analizy.

Po etapie selekcji cech przetestowano trzy warianty modelu końcowego. Pierwszy z nich opierał się na regresji logistycznej i pełnił rolę prostego punktu odniesienia po redukcji liczby zmiennych. Drugi wariant wykorzystywał algorytm Random Forest jako model końcowy, co pozwalało uchwycić nieliniowe zależności pomiędzy cechami. Trzeci wariant opierał się na algorytmie typu boosting, w którym kolejne modele uczą się na błędach poprzednich, umożliwiając stopniowe doskonalenie predykcji.

Każdy z wariantów został oceniony z wykorzystaniem pięciokrotnej walidacji krzyżowej z zachowaniem proporcji klas w poszczególnych podziałach. Jako miarę jakości zastosowano balanced accuracy, co pozwoliło na uczciwe porównanie skuteczności modeli niezależnie od rozkładu klas. Dodatkowo analizowano stabilność wyników pomiędzy kolejnymi podziałami walidacji, aby upewnić się, że uzyskane rezultaty nie są efektem losowego podziału danych.

Na podstawie uzyskanych wyników (Tabela 1) jako najlepszy wariant wybrano podejście łączące selekcję cech opartą na Random Forest oraz Random Forest jako model końcowy. Wariant ten osiągnął najwyższą średnią wartość balanced accuracy przy jednocześnie stabilnych wynikach w kolejnych iteracjach walidacji krzyżowej (Tabela 2). Wybrany model został następnie poddany eksperymentom w celu osiągnięcia jego maksymalnej skuteczności.

Model	Mean BA	Std BA
A1.2 RF-select + RF	0.8707	0.0269
A1.3 RF-select + Boosting	0.8168	0.0341
A1.1 RF-select + LR	0.5986	0.0246

Tabela 1: Porównanie wariantów modelu A1 z selekcją cech opartą na Random Forest, propozycje są uszeregowane od najlepszej

Fold	Balanced Accuracy
Fold 1	0.8801
Fold 2	0.8736
Fold 3	0.9000
Fold 4	0.8199
Fold 5	0.8798

Tabela 2: Wyniki walidacji krzyżowej (5-fold) dla najlepszego modelu A1.2 RF-select + RF

5 Dobór hiperparametrów i optymalizacja modelu

W celu dalszej poprawy jakości predykcji przeprowadzono optymalizację wybranego modelu A1.2 (RF-select + RF). Proces optymalizacji obejmował dwa kluczowe elementy: dobór liczby cech pozostawianych po etapie selekcji zmiennych oraz dostrajanie hiperparametrów modelu Random Forest.

W pierwszym kroku analizowano wpływ liczby wybranych cech K na wartość miary balanced accuracy, testując kilka wariantów w ustalonym zakresie. Pozwoliło to ocenić kompromis pomiędzy redukcją szumu a zachowaniem istotnego sygnału predykcyjnego. Analizowano wartości liczby cech $K \in \{5, 10, 20, 30, 40, 60, 100\}$. (wejściowych cech było 100), a wyniki reprezentuje Tabela 3. Jako najskuteczniejsze ograniczenie została wyłoniona liczba cech 20.

Liczba cech K	Mean BA	Std BA
20	0.8707	0.0255
30	0.8614	0.0266
10	0.8455	0.0379
40	0.8415	0.0302
60	0.8182	0.0296
100	0.8003	0.0317
5	0.7868	0.0280

Tabela 3: Wpływ liczby wybranych cech K na wartość balanced accuracy dla modelu A1.2 (RF-select + RF)

W drugim kroku przeprowadzono strojenie hiperparametrów modelu końcowego Random Forest z wykorzystaniem walidacji krzyżowej. W ramach siatki parametrów uwzględniono maksymalną głębokość drzew oraz minimalną liczbę obserwacji w liściu, które kontrolują złożoność modelu i jego podatność na przeuczenie

$$\text{max_depth} \in \{\text{None}, 8, 12\}, \quad \text{min_samples_leaf} \in \{1, 2, 5\}.$$

Wszystkie warianty oceniano z użyciem tej samej procedury walidacji krzyżowej oraz miary balanced accuracy, oraz najefektywniejsze z rozważanych parametrów

$$\text{max_depth} = \text{None}, \quad \text{min_samples_leaf} = 1.$$

zostały przypisane do końcowego modelu, który następnie wytrenowano i użyto do uzyskania predykcji na zbiorze testowym. Ostateczna wartość miary BA wyniosła 0.871.

6 Podsumowanie i wnioski

Po szeregu wykonanych eksperymentów model został wytrenowany na zbiorze treningowym z wykorzystaniem zoptymalizowanej liczby cech oraz najlepiej dobranych hiperparametrów. Proces budowy modelu obejmował etap wstępnego przetwarzania danych, selekcję cech opartą na Random Forest, a następnie strojenie hiperparametrów modelu końcowego z użyciem walidacji krzyżowej. Tak przygotowany model został wykorzystany do predykcji na zbiorze testowym, a efekty są dostępne w osobno załączonym pliku txt.